

익명 투표 앱 유저 분석 및 결제 예측 자동화

질문 카테고리 중심 하트 소비 패턴 분석과 결제/비결제 예측 모델의 Airflow 기반 자동화



6팀 김필준, 류제범, 유윤종, 이혜주

CONTENTS

01 프로젝트 개요

02 데이터 소개

03 데이터 전처리

04 탐색적 데이터 분석 (EDA)

05 결제 예측 모델링

06 모델 성능 비교

07 Airflow 기반 자동화

08 활용방안

01

프로젝트 개요



익명 투표 앱 유저 분석 및 결제 예측 자동화

이번 그룹 프로젝트는 어플리케이션의 로그를 바탕으로 **유저의 행동을 정의**하고 이를 활용하여 **결제를 예측하는 모델 개발, 예측 및 평가**를 수행하였습니다.

추가로 제공된 원본 로그 데이터를 활용하여 **테이블 생성, 전처리, 모델링, 예측 및 평가 과정을 자동화**하여 데이터가 쌓여감에 따라 어떠한 과정으로 자동화하는지 실습하였습니다.

02

데이터 소개

| 데이터 기간 : 2023.07.18 ~ 2023.08.10 (약 4주)

| 사용 데이터 : SNS 서비스(익명 투표 앱)의 서비스 내부 데이터 및 유저 이벤트 데이터

서비스 내부 데이터	유저 이벤트 데이터
총 21개의 테이블	총 4개의 테이블

03

데이터 전처리

session_id, user_id, device_id는 서로 다른 고유값을 가지고 있어야 한다.

전체 데이터 행 수 : 261,594개

session_id

“-”이 포함되지 않은
랜덤한 문자열

규칙 준수 : 261,591개 (100.00%)

user_id

숫자로만 이루어진
문자열

261,580개 (99.99%)

device_id

“-”이 포함된 랜덤한
문자열

261,594개 (100.00%)

처리 방식 : 해당 규칙을 따르지 않는 행 **제거**

03

데이터 전처리

문제 상황 하트 소비 및 획득과 관련이 없는 event_key 임에도 하트 보유량의 변화가 존재

event_key	heart_balance	정상 여부
\$session_start	50	×
complete_purchase	100	✓
launch_app	-30	×

item_name에 명시된 하트량에 따라
heart_balance 증가 여부 확인



item_name 값과 일치하는
하트 증가량 건수 : 22건

⇒ heart_balance는 믿을 수 없는 데이터

처리 방식 : 추후 분석 및 모델링 과정에서 heart_balnce 컬럼 **제거**

03

데이터 전처리

※ user_id별 event_datetime으로 정렬했을 때, 최초로 기록된 event_key의 종류 및 빈도

event_key	count
\$session_start	70,077
launch_app	61,854
\$session_end	25,737

앱 진입 또는 활성화 시 발생하는
시스템 이벤트로 추정
(둘 다 “시스템 진입”에 해당)

연속성 검증 결과 : \$session_start와 launch_app이 연속으로 나타나는 비율 **65.51%**

(전체 유저 중 이벤트 기록이 2개 이상인 유저 기준)

처리 방식 : \$session_start와 launch_app 키를 묶어 하나의 “어플 실행” 이벤트로 간주하여,
유저의 앱 사용 시작 지표로 활용

03

데이터 전처리

※ user_id별 event_datetime으로 정렬했을 때, 최초로 기록된 event_key의 종류 및 빈도

event_key	count
\$session_start	70,077
launch_app	61,854
\$session_end	25,737

첫 이벤트로 등장한 횟수

전체 \$session_end (626,000건) 중
4%가 첫 이벤트로 등장
→ 세션 종료 의미에 대해 신뢰도 ↓

또 다른 문제 : 전체 중 114,000건은 \$session_end 직후 이벤트가 0초 이내 발생
→ 종료 이벤트가 중간에 오기록 되었을 가능성

⇒ 즉, 기존에 존재하는 \$session_end는 세션 종료를 의미하는지 파악 불가능

처리 방식 : 기존 \$session_end 제거 후, 20분간 활동 없을 시 → 새로운 \$session_end 생성

03

데이터 전처리

문제 상황 user_id별 event_datetime으로 정렬했을 때, 연속된 중복 event_key 기록이 존재

유저 A 타임라인

event_datetime	event_key
2023-07-19 17:55:14	view_home_tap
2023-07-19 17:56:39	click_question_start
2023-07-19 17:56:40	click_question_start
2023-07-19 17:56:45	click_appbar_friend_plus
2023-07-19 17:57:59	click_appbar_friend_plus



유저 A 타임라인

event_datetime	event_key
2023-07-19 17:55:14	view_home_tap
2023-07-19 17:56:39	click_question_start
2023-07-19 17:56:45	click_appbar_friend_plus

처리 전 : 7,642,923행 → 처리 후 : 6,725,683행
 ➡ 총 917,240행 (약 12%) 감소

처리 방식 : 동일한 이벤트가 중복으로 나올 시, **최초**의 이벤트 기록만 **유지**하고 **남은 중복 기록은 제거**

04

탐색적 데이터 분석 (EDA)

※ event_key 카테고리 설립

카테고리	event_key	상세 설명
app 실행 및 세션 시작	lunch_app	
	session_start	
세션 종료	session_end	
메인/홈 진입	view_home_tap	
	view_lap_tap	
하단 네비게이션 클릭	click_bottom_navigation_lab	
	click_bottom_navigation_profile	
	click_bottom_navigation_question	
	click_bottom_navigation_timeline	
상단 앱바 클릭	click_appbar_alarm_center	
	click_appbar_chat_rooms	
	click_appbar_friend_plus	
	click_appbar_setting	

04

탐색적 데이터 분석 (EDA)

※ event_key 카테고리 설립

카테고리	event_key	상세 설명
회원가입/로그인	complete_signup	
	view_login	
	view_signup	
하트 구매 관련	click_purchase	
	complete_purchase	
	view_shop	
질문 카테고리	click_question_start	시작/생성
	click_qusetion_ask	
	click_random_ask_normal	
	click_random_ask_other	
	click_random_ask_shuffle	
	click_profile_ask	
	complete_question	

04

탐색적 데이터 분석 (EDA)

※ event_key 카테고리 설립

카테고리	event_key	상세 설명
질문 카테고리	click_qusetion_open	조회/관리
	view_question_tap	
	skip_question	건너뛰기
	click_question_share	공유/링크
	click_copy_profile_link_ask	
친구/소셜 기능	click_autoadd_contact	
	click_friend_invite	
	click_invite_friend	
채팅기능	click_community_chat	
	click_timeline_chat_start	

04

탐색적 데이터 분석 (EDA)

※ event_key 카테고리 설립

카테고리	event_key	상세 설명
프로필/계정 관리	view_profile_tap	
알람기능	click_notice	
	click_notice_detail	
타임라인/피드 보기	view_timelint_tap	
기타	button	
	click_attendance	
	click_copy_profile_link_profile	


04

탐색적 데이터 분석 (EDA)

| 소비 유도에 기여하는 행동 경로 분석

목적 : 유저들이 '하트 관련 소비 행동'을 하기 직전에 어떤 행동을 했는지 분석하여,
소비 유도에 기여하는 행동 경로를 파악

'complete_purchase' 이벤트
직전 행동 이벤트 키 빈도



구매 완료(complete_purchase) 직전 패턴 :

- 하트 상품 클릭(click_purchase)이 압도적으로 많음 (1603회)
- 하트 충전소 진입(view_shop)이 구매 완료로 직접 이어지는 경우는 매우 적음 (6회)


04

탐색적 데이터 분석 (EDA)

| 소비 유도에 기여하는 행동 경로 분석

목적 : 유저들이 '하트 관련 소비 행동'을 하기 직전에 어떤 행동을 했는지 분석하여,
소비 유도에 기여하는 행동 경로를 파악

확장된 '소비' 이벤트 (complete_purchase, click_purchase, view_shop) 직전 행동 이벤트 키 빈도



view_shop : 상점을 본 후 다시 구매로 이어지는 경우 많음

질문 관련 : 유저가 질문을 본 직후 소비로 이어지는 경향이 높음

click_attendance : 보상성 기능 (출석 등)이 소비 유도에 연결됨


앱 실행 관련 : 앱 실행 직후 바로 소비로 이어진 유저 다수 존재

04

탐색적 데이터 분석 (EDA)

| 하트/구매 관련 활동 직전 행동 확장 분석

목적 : 유저들이 하트 소비 행동을 하기 직전에 어떤 '카테고리의 행동'을 했는지를 파악




04

탐색적 데이터 분석 (EDA)

하트/구매 관련 활동 직전 행동 확장 분석

목적 : 유저들이 하트 소비 행동을 하기 직전에 어떤 '카테고리의 행동'을 했는지를 파악



★ 출석 체크 및 기타 유틸리티에서의 소비 유도

- 기타 기능 (2,761건) 중 상당수는 click_attendance (출석 체크)
- 리워드를 받은 뒤 바로 소비행동으로 이어지는 흐름 존재

★ 앱 실행 직후, 홈 진입 직후 소비

- 앱을 키자마자 소비하는 유저가 많음 (앱 실행 1,586건)
- 홈에서 소비 진입하는 경우도 적지 않음 (홈 진입 489건)

★ 저빈도지만 주목할 흐름

- 알림 → 소비로 가는 흐름 : 393건 존재
 - 특정 알림이 소비로 이어졌을 가능성 있음
- 친구/소셜 → 소비로 가는 흐름 : 98건 존재
 - 소비 전환율은 낮지만, 소비 유도로 이어지는 UX 기획 여지 있음


04

탐색적 데이터 분석 (EDA)

질문 카테고리 연계 분석

목적 : 질문 카테고리 이후 유저의 흐름 파악

‘소비’ 직전 질문 관련 카테고리 이벤트 키 빈도



직전 '질문' 관련 이벤트 키

총 8,628건의 '질문' 관련 활동 중 다수는 특정 이벤트에 집중

- 1위 : `click_question_open` (6,610회)
→ 하트/구매 전환 핵심 순간
- 2, 3위 : `view_questions_tap` (956회),
`complete_question` (619회)
→ '질문 탐색·생성 완료'도 구매 전환 기여
- `click_question_start` (286회),
`click_question_ask` (59회) 등
→ 빈도 낮지만 하트/구매 전환 발생
- `skip_question` (55회), `click_question_share` (40회) 등
→ 전환 연관성 낮음


04

탐색적 데이터 분석 (EDA)

질문 카테고리 연계 분석

목적 : 질문 카테고리 이후 유저의 흐름 파악

‘소비’ 직전 질문 관련 카테고리 이벤트 키 빈도



직전 '질문' 관련 이벤트 키

결론

- ‘질문’ 기능은 하트/구매와 강하게 연결
- 유저가 질문 내용을 적극적으로 탐색·상호작용하는 시점에 하트/구매 필요 인지
- UI/UX 개선 및 마케팅 전략 수립의 핵심 단서


04

탐색적 데이터 분석 (EDA)

질문 카테고리 세분화

목적 : 질문 카테고리에 해당하는 내용이 많기 때문에 이를 구체화할 필요성 존재

‘소비’ 직전 ‘질문’ 세분화 카테고리 빈도



• 질문 조회/관리 (7,566회)

- ‘소비’ 직전 질문 활동의 **대부분(약 87.7%)**을 차지
- 하트 필요 핵심 트리거:
질문 열람·목록 확인 시 하트 필요성 가장 큼

• 질문 시작/생성 (967회)

- 두 번째로 높은 빈도 (약 11.2%)
- 구매 기회 발생 지점:
질문 작성·시작 시 하트 필요성 발생

• 질문 건너뛰기 (55회) 및 질문 공유/링크 (40회)

- 매우 낮은 빈도 (합쳐서 약 1.1%)
- 구매 연관성 낮음: 구매 동기 유발 거의 없음

04

탐색적 데이터 분석 (EDA)

일반 유저 vs 주요 유저 비교 분석

유저 그룹 정의

주요 유저 = 서비스에 깊이 관여하는 핵심 집단

(주요 유저 분류 기준 : 전체 유저 중 이벤트 수가 상위 10% 이상)


전체 유저 수	169,115명
주요 유저 수	17,140명
일반 유저 수	151,975명

04

탐색적 데이터 분석 (EDA)

일반 유저 vs 주요 유저 비교 분석

유저 그룹별 이벤트 카테고리별 활동 비율



일반 유저 vs 주요 유저 활동 패턴 차이 분석

- 참여도 및 기능 활용의 깊이 차이
 - 주요 유저는 질문 관련 이벤트 비율이 15.3%로 일반 유저(11.74%)보다 약 30% 더 활발하게 참여
- 세션 종료 이벤트도 주요 유저에서 더 높은 비중 (7.69%)을 차지
 - 더 긴 세션 혹은 여러 기능을 이용 후 종료하는 경향을 보이며, 의도적 이용 패턴을 시사
- 기타 기능/설정/유틸리티, 프로필 관리, 하트/구매 관련 기능 등 부가 기능 활용 비율도 주요 유저가 전반적으로 높음
 - 서비스의 심화 기능까지 탐색하고 활용하는 유저군

04

탐색적 데이터 분석 (EDA)


| 일반 유저 vs 주요 유저 비교 분석



전체 이벤트의 **44% 이상**을 생성하며 서비스에 깊이 관여

- 질문 생성 및 세션 종료 비중이 높음
- 다양한 기능을 적극 활용하는 경향

➡ 단순 탐색에 그치는 일반 유저와 뚜렷이 구별



따라서, 서비스 개선 및 전략 수립 시에는
주요 유저의 행동 패턴을 중심으로 분석하
는 것이, 실질적인 서비스 성과를 높이는 데
있어 더욱 효과적임

⇒ **주요 유저**를 대상으로 분석



04

탐색적 데이터 분석 (EDA)

가설 : 활동량이 높을수록 결제를 할 확률이 높아진다.

결제 여부 정의 : 'complete_purchase' 발생 유저 → 결제 유저

활동량 정의 : 각 유저의 총 이벤트 수



04

탐색적 데이터 분석 (EDA)

| 가설 : 활동량이 높을수록 결제를 할 확률이 높아진다.

 통계적 검정 : Mann-Whitney U 검정(비모수 검정)

→ 데이터가 정규 분포를 따르지 않아 중앙값 비교에 유리한 비모수 검정 사용

귀무가설(H_0) : 결제 유저와 비결제 유저의 활동량은 차이가 없다.

대립가설(H_1) : 결제 유저의 활동량 중앙값이 비결제 유저보다 유의미하게 높다.

Mann-Whitney U 통계량: 181273374.5 | P-value: 0.0000

- U-통계량↑ → 결제 유저 활동량 순위가 전반적으로 비결제 유저보다 높음
→ 두 그룹 간의 활동량 차이가 더 명확하다는 신호 중 하나
- 결제 유저의 활동량이 통계적으로 유의미하게 더 높다

⇒ 최종 결론 : "활동량이 높을수록 결제를 할 확률이 높아진다"는 가설에 대한 **강력한 증거 확보**

04

탐색적 데이터 분석 (EDA)

가설 : 활동량이 높을수록 결제를 할 확률이 높아진다.

▶ 총 이벤트 수 외의 추가 보조지표를 통한 검증


- 총 세션 수 : 앱 방문 빈도
- 활성 일 수 : 앱 사용 지속성
- 핵심 기능 이벤트 수 : 주요 기능(질문 관련) 사용 심화 정도

⇒ 추가 지표를 넣어도 **유의미한 결과 도출**

? 의문점 :

활동량이 낮을수록 결제를 안 하는 현상은 일반적인 현상으로 이 그룹의 규모와 특성을 명확히 파악할 필요 있음



→ 이를 해결하기 위해 **유저 군집 분석 진행**



04

탐색적 데이터 분석 (EDA)

| 유저 활동량 군집화로 본 결제 행동





엘보우 차트에서는 최적 군집 수가 4로 나타났으나,
결제 유저가 비결제 유저에 비해 현저히 적은 점을 고려하여
각 군집의 명확한 분류와 실무 적용 용이성을 위해 군집 수를 3으로 설정

군집	유저 수	총 세션	활동일수	핵심 이벤트	결제율	주요 특징
1	207.34	20.9	12.07	31.37	2.74	일반 활동 / 잠재 유저
2	1260.8	119.17	21.31	314.2	2.5	고활동/핵심 유저
0	28.69	1.85	2.07	3.47	0.64	저활동/비활성 유저

04

탐색적 데이터 분석 (EDA)

| 유저 활동량 군집화로 본 결제 행동




- 🚩 활동량이 결제율과 선형 관계가 아닐 수 있음
- 가설인 “활동량이 높을수록 결제율이 증가한다”는 전제를 군집 1과 2가 깨고 있음
- 오히려 너무 높은 활동량을 보이는 일부 유저(군집 2)는 결제와 무관하거나, 결제 니즈가 낮을 수도 있음
- 따라서, 단순히 활동량이 많다고 해서 유료 전환 가능성이 더 높다고 보기 어려움

04

탐색적 데이터 분석 (EDA)

| 군집 1+2 통합 분석 : 활동 유저 전체 vs 결제 여부

목적 : 군집 1 & 2(활동량이 높은 그룹)에서 결제 유저 vs 비결제 유저의 활동량을 비교하여, 활동량이 결제율에 영향을 주는지 확인



- 총 이벤트 수에서 **결제 유저 활동량**이 뚜렷하게 높음
 - 결제 유저가 서비스 내에서 더 많은 행동을 수행 의미
 - 특히 심화된 활동·몰입도 높은 사용의 신호
- 세션 수/활동일수는 큰 차이가 없거나 비결제 유저가 더 많음
 - 단순히 자주 방문한다고 해서 결제로 이어진 않음을 시사
 - 방문 빈도보다는 방문당 활동량이 더 중요한 요인일 수 있음

04

탐색적 데이터 분석 (EDA)

| 비교 분석 : 군집 1 vs 군집 2

✓ 군집 1

결제자 vs 비결제자 평균 총 이벤트 수 차이
(P-value) : 0.0000

총 이벤트 수 vs 결제여부 상관계수 : 0.1052

- 활동량 ↑ → 결제 가능성 유의하게 ↑
- 결제자와 비결제자의 활동량 차이도 유의미
- 활동량이 높은 유저를 타겟으로 결제 유도 전략을 세우는 것이 효과적

⊘ 군집 2

결제자 vs 비결제자 평균 총 이벤트 수 차이
(P-value) : 0.4919

총 이벤트 수 vs 결제여부 상관계수 : -0.0261

- 활동량 ↑ → 오히려 결제 ↓ 경향
- 활동량과 결제 여부 사이에 유의한 차이 없음
- 콘텐츠·마케팅 등 다른 요인의 결제 영향 가능성 큼

⇒ 결제 예측 모델링 시, 군집 2처럼 활동량 지표만으로 예측이 어려운 그룹은 모델 성능이 저조할 수 있음
→ 이는 현재 가진 데이터(활동량 지표)만으로는 해당 그룹의 결제 행태를 설명하기 어려움을 보여줌

05

결제 예측 모델링

| 모델 구축 프로세스

전처리

학습에 적합한 데이터 테이블 생성
전처리 및 피처 엔지니어링 수행

모델 학습 및 튜닝

XGBoost·LightGBM·CatBoost
모델에 대해 하이퍼파라미터 튜닝
(Stratified 5-Fold 교차검증) 수행

모델 평가

ROC-AUC·PR-AUC
기준 성능 평가
Precision, Recall로
오탐 비율 측정

모델 배포

클라우드 자동화를 위해
.pkl 형식으로 모델 배포



06

모델 성능 비교

| 모델 성능 평가 비교 표

Model	HPO	ROC-AUC	PR-AUC	Non-Payer Precision	Payer Precision	Non-Payer Recall	Payer Recall
XGBoost	Baseline	0.8936	0.0851	0.99	0.20	1.00	0.14
	Grid Search	0.9007	0.0910	0.99	0.21	1.00	0.13
	Random Search	0.9007	0.1038	0.99	0.16	0.99	0.22
	Optuna	0.9126	0.1002	1.00	0.06	0.92	0.67
LightGBM	Baseline	0.9074	0.1066	0.99	0.20	0.99	0.21
	Grid Search	0.9054	0.0984	0.99	0.20	1.00	0.12
	Random Search	0.9064	0.0975	0.99	0.17	0.99	0.20
	Optuna	0.9145	0.1035	1.00	0.05	0.90	0.71
CatBoost	Baseline	0.8965	0.1044	0.99	0.23	1.00	0.05
	Grid Search	0.8936	0.0911	0.99	0.14	1.00	0.04
	Random Search	0.9056	0.0904	0.99	0.19	1.00	0.05
	Optuna	0.9156	0.1139	1.00	0.07	0.93	0.66

06

모델 성능 비교

| 성능 평가 및 최종 모델 결정

 성능 평가 요약

- 'Payer' 클래스의 데이터 불균형 문제 해결을 위해 ADASYN 오버샘플링을 각 훈련마다 적용하여 모델을 적합 → 이를 통해 소수 클래스 패턴 학습 환경을 구축
- 오버샘플링 후, Optuna 방식의 LightGBM이 Payer 탐지율에서 가장 높은 성과 (0.71)를 보였으나, Baseline LightGBM도 안정적이고 준수한 성능을 기록


 최종 모델 선정: Baseline LightGBM

- 선정 이유
 - a. 전체 파이프라인 효율성 : 가벼운 모델이 안정적으로 실행되는 데 필수적
 - b. 운영 안정성과 예측 일관성 : 복잡한 튜닝 없이 일관된 성능 제공, 오류 가능성 감소
 - c. 비용 대비 최고의 성능 : PR-AUC (0.1066)와 Payer Recall (0.21)에서 가장 높은 성과를 기록

06

모델 성능 비교

SHAP Feature Importance




평균 절대 SHAP 값

- 전체 데이터에서 어떤 피처가 예측에 가장 큰 영향을 주는지 순위화하는 플롯
- 상위 중요 피처:
 - num_total_events: 전체 이벤트 수 (가장 큰 영향)
 - num_core_events: 핵심 이벤트 수
 - nom_gender_F: 성별(여성 여부)
 - num_active_days: 활동일수
 - ord_school_grade: 학년
- 활동량(이벤트 수, 핵심 이벤트 수, 활동일수)이 결제 여부 예측에서 매우 중요한 역할을 하며, 인구통계 속성(성별, 지역, 학년)도 영향을 미침

06

모델 성능 비교

SHAP Beeswarm Plot




피처별 값 분포와 영향 방향

- 각 피처 값의 크기(색상)와 예측에 미치는 영향 (좌우 방향)을 시각적으로 표시하는 플롯
- num_total_events:
 - 값이 낮을수록 SHAP 값이 음수 → 결제 확률 감소
 - 값이 높을수록 양수 → 결제 확률 증가
- num_core_events: 유사하게 값 ↑ → 결제 확률 ↑
- nom_gender_F: 여성일 경우 예측에 양/음 방향 혼재
→ 하지만 대체로 결제 확률 증가에 기여
- num_active_days: 활동일이 ↑ → 양수 방향에 기여
→ 값이 높을 수록 결제 확률 증가
- 지역(nom_province_*)은 특정 지역에 따라 결제 확률에 미치는 영향이 다르게 나타남

06

모델 성능 비교

SHAP Waterfall Plot



개별 예측에 대한 설명 플롯

- 피쳐 샘플 (첫 번째 예측)에 대해 모델이 왜 해당 값을 예측했는지를 보여주는 플롯
- $f(x) = -5.73$ 는 로그 스케일의 최종 예측값이며, 기준값 ($E[f(X)] = 0.02$)에서 각 피쳐가 얼마나 이동시켰는지를 보여줌
- num_core_events (핵심 이벤트 수), nom_gender_F (여성 여부), num_friend_id_count (친구 수), num_total_events 등이 예측 값을 낮추는 방향 (음수 SHAP 값)으로 작용함을 확인할 수 있음
- 즉, 이 샘플에서는 핵심 이벤트, 전체 이벤트 수, 친구 수가 적거나 특정 속성 값 때문에 결제할 가능성이 낮아졌다는 것을 시사

07

Airflow 기반 자동화

Airflow 자동화 파이프라인 구성

데이터 업로드

원본 로그 데이터(JSON)활용
6개월 테이블 제작
빅쿼리에 업로드

전처리

병합 및 피쳐 생성 등
모델 적용 가능한 테이블 생성

모델 적용

생성된 최종 테이블 활용하여
모델에 적용

예측 및 평가


매 달 축적된 데이터 활용
모델을 통해 예측 및 평가 수행




07

Airflow 기반 자동화

| 데이터 업로드 (json_to_table)



원본 로그 데이터



Python Operator 활용 (json_to_table)

- Python Operator를 활용하여 원본 로그 데이터를 4개의 hackle 테이블로 만들어 저장
- 저장된 4개의 테이블을 Big Query 데이터셋에 업로드 하는 DAG 파일 활용
→ json_to_table, upload_to_bq 자동화
- 기존 hackle 데이터(2023-07) 기준 이후 6개월치 데이터 매일 1개월치씩 업로드

07

Airflow 기반 자동화

전처리 및 모델링

전처리 및 모델 예측 자동화

codeit-final-project

All 5 Active 4 Paused 1 Running 0 Failed 1 Filter DAGs by tag Search DAGs

DAG	Owner	Runs	Schedule	Last Run	Next Run
☒ airflow_monitoring	airflow	431	*10 ****	2025-08-09, 06:40:00	2025-08-09, 06:50:00
☐ daily_payment_prediction_pipeline bigquery bqml gcp	airflow	1	@daily	2025-08-09, 04:06:42	2025-08-08, 15:00:00
☒ daily_payment_prediction_pipeline_undersampled bigquery bqml gcp undersampled	airflow	3	@daily	2025-08-09, 05:32:15	2025-08-08, 15:00:00
☒ daily_payment_prediction_pipeline_weighted bigquery bqml gcp weighted	airflow	2	@daily	2025-08-09, 04:56:34	2025-08-08, 15:00:00
☒ json_to_bq_dag_v4	airflow	1	@daily	2025-08-08, 02:04:49	2025-08-09, 00:00:00

1

- Big Query에 업로드 된 월별 4개의 테이블을 활용하여 기존 데이터(2023-07)와 동일하게 전처리 및 모델 적용
- Big Query 업로드 다음날 업로드된 1달치 데이터에 대한 예측 및 평가 수행
- 기존 데이터를 활용한 모델로 예측 및 평가 진행할 예정이었으나 **OOM 문제**로 인해 실패, 다양한 방식 시도
- 모델.pkl 파일 생성하여 **Google Cloud Run**을 통해 서비스 배포 시도하였으나 **제한된 리소스**로 인해 적용 실패
- 이외에도 다양한 방식으로 위 문제를 해결하기 위해 시도하였으나 적절한 해결책을 발견하지 못하여 **Big Query 내에서 기존 모델과 가장 근사한 성능의 모델을 생성하여 예측 및 평가 진행**

07

Airflow 기반 자동화

예측 및 평가



8월 예측 및 평가 (default)

- Big Query에 업로드 된 8월 테이블을 활용하여 모델 예측 및 평가 진행
- 정확도 약 89%로 높게 나오나 정밀도 1.0, 재현율 0.03으로 의미있는 결과 나오지 않았음
- 소수 클래스(결제 0)의 수가 너무 적어 발생한 문제로 보이며, 이를 해결하기 위해 클래스 불균형 해소를 적용하여 다시 수행

07

Airflow 기반 자동화

예측 및 평가




8월, 9월 예측 및 평가 (CLASS_WEIGHT)

- 자동화 성공
- 정확도 기존 대비 23%가량 하락하였으나, F1-score 0.27로 불균형 문제 다소 해결된 것으로 보임
- Sampling 기법 등 다양한 클래스 불균형 해소 기법 적용 시도하였으나 **OOM 문제 및 리소스의 제한**으로 인해 적용 실패
- 추후 기존 모델과 동일한 튜닝을 거친 모델로 **개선** 여지 있음

08

활용방안



Demo App 앱 오후 7:31
 🎉 모델링 파이프라인 완료!
 🚀 모델링 파이프라인 주요 결과 🚀

- Best Threshold: 0.2462
 - Test ROC AUC: 0.9043
 - Test PR AUC: 0.0978

Classification Report:

	precision	recall	f1-score	support
Non-Payer	0.99	0.99	0.99	32943
Payer	0.16	0.26	0.20	243
accuracy			0.99	33186
macro avg	0.58	0.62	0.60	33186
weighted avg	0.99	0.99	0.99	33186

슬랙에 결과물 전송하는 데모 서비스 구현

- 적용 모델 고도화, 파이프라인 세분화 (각 단계별 추가 작업)
- 슬랙, 노션 등을 통해 매달 예측 및 평가 결과를 전송하는 서비스
- 해당 서비스를 통해 더 많은 결제 유저 예측 → 수익 극대화

감사합니다