

PROJECT 1

구독형 강의 서비스의 첫 날 이탈 사용자 재방문 개선을 위한 데이터 분석

프로젝트 기간: 2025. 04. 07 ~ 2025. 04. 30
이름: 유윤종
yooyoon97@gmail.com

프로젝트 개요

- 높은 초기 이탈 문제를 해결하기 위해 최소 1개 이상의 수강 경험 (이하 Aha-Moment) 이후 행동으로 사용자를 세분화 하고, 행동 패턴 분석 결과를 바탕으로 개선 전략과 A/B 테스트를 설계하였다.

분석 배경

- 디지털 전환 가속화와 학습 주체의 자율성 확대, 시·공간 제약 해소로 온라인 교육 시장이 급격히 성장함
- 오프라인 강의가 비대면 콘텐츠로 전환되는 동향에 맞춰 맞춤형 강의 제공 및 효율적인 학습의 수요 증가

분석 목표

- 구독형 강의 서비스 사용자의 전반적인 학습 여정 로그 데이터 분석
- 사용자 집단 (세그먼트) 별 행동 패턴 및 리텐션 분석
- A/B 테스트 기반 재방문 유도 전략 제안

실험 가설


“Aha-Moment를 겪은 다음 날(1일차), 서비스에 다시 방문한 사용자 집단은 이탈 집단 대비 **KPI 지표**가 유의미하게 높다”

사용 데이터

- 22년 1월부터 23년 12월까지의 온라인 교육 콘텐츠 구독서비스의 사용자 행동 로그 데이터 테이블
- 140,000명의 회원가입자의 활동 로그와 관련된 테이블과 로그로 구성되어있음
- 주요 테이블: 레슨 시작 (enter.lesson_page), 구독 완료 (complete.subscription)

분석 과정

- 데이터 전처리
 - 회원 가입을 한 사용자 ID를 추출하여 새로운 사용자 정보 테이블 생성
- 탐색적 자료 분석





- 신규 가입자가 계속 감소하는 추세를 보였으나, 프로모션 및 신년 새 학습 계획을 결심하는 사용자들에 힘입어, 23년 1월에 급증하였음.

주요 코호트의 롤링 리텐션 히트맵

코호트	D0	D1 생존율	D7 생존율	D14 생존율	D28 생존율
Jan-22	1.0000	0.3960	0.3570	0.3380	0.3120
Nov-22	1.0000	0.4890	0.4460	0.4190	0.3530
Feb-23	1.0000	0.3030	0.2370	0.2000	0.1680
Aug-23	1.0000	0.2790	0.2040	0.1740	0.1380

- 0일차 → 1일차 평균 롤링 리텐션이 대부분 크게 감소하는 경향을 확인함
- 즉, 1일차 재방문이 서비스의 리텐션 개선의 최우선 허들이라고 할 수 있음



- 0일차 이탈자
 - 중앙값 약 2회, IQR 약 1~4회 → 전체 수강 횟수가 낮아 학습 몰입도가 부족.
 - 짧은 학습 시간으로 서비스 체험이 제한적임.
- 1일차 재방문자
 - 중앙값 약 7회, 3사분위수 약 12회 → Day 0 이탈자(중앙값 약 2회)에 비해 훨씬 많은 레슨을 완료하였음.
 - 평균 학습 시간이 비교적 길기 때문에 학습 몰입도가 크다고 볼 수 있음.

분석 인사이트


구분	활동 일 수 (일)	결제 전환률 (%)	일 평균 세션 체류 (회)	ARPPU (원)
0일차 이탈자	1.55	8.02	0.1	76,469
1일차 재방문자	8.04	47.49	1.5	74,572

- 0일차 이탈자 : 평균 활동 일수 1.55일, 일 평균 세션 체류 0.1회 → 체험 단계에서 빠르게 이탈, 서비스 이해 부족. 결제 전환율 8.02%에 불과해, 단기 체험만으로는 유료 전환 동기 부여가 미흡
- 1일차 재방문자 : 평균 활동 일수 8.04일, 일 평균 세션 체류 1.5회 → 적극적 서비스 이용 및 학습 몰입도 높음. 결제 전환율 47.49%로 월등히 높아, 재방문 이후 ‘유료 전환’ 가능성이 크게 상승
- ARPPU(사용자당 평균 매출) 비교: 이탈자의 개별 지불액은 약간 높으나, 재방문자의 높은 전환율 덕분에 전체 매출 기여도는 재방문자 세그먼트가 더 큼


개선 사항 제안 및 기대 효과

전략	설명	기대 효과 및 KPI
게이미피케이션	행동 지표를 기반으로 유저에게 시각적·심리적 보상을 제공하여 동기 강화	- 치장 아이템 획득율 - 평균 세션 수 증가율 - 결제 전환율 변화
분기·시즌 별 마케팅 및 프로모션 강화	시즌 수요를 활용해 단기 유입을 증대, 이후 연속 결제 및 리텐션 을 유도	- 프로모션 코드 사용률 - 첫 결제 후 재구독 비율 - 구독 지속 기간 및 LTV 비교
장기 충성 사용자 대상 특별 혜택 강화	최상위 LTV 유저(파워 유저)를 식별해 이탈 방지 및 독점적 경험 제공	- 독점 콘텐츠 참여율 - 파워 유저의 리퍼럴 수 - 파워 유저가 유입 시킨 유저 의 LTV 비교

A/B 테스트 설계



Control 집단 대시보드



Treat 집단 대시보드

가설

- 문제 인식: 사용자들의 1일차 재방문율이 낮아 후속 전환의 기회가 상실됨.
- 가설: 메인 대시보드에 칭호와 학습 상황과 같은 게이미피케이션 요소를 삽입하면 1일차 재방문율과 결제 전환률이 상승할 것이다.

설계

구분	Control	Treat
화면 구성	기본 수강 목록만 노출	챌린지 칭호 + 수강목록 노출
Call To Action	“학습 이어가기” 버튼	챌린지 칭호 클릭 → 보상 안내 노출
타겟 사용자	Day 0 이탈 위험 세그먼트	동일 세그먼트

지표

- Primary KPI: 1일차 재방문율
- Secondary KPIs: 결제 전환률, ARPPU, 하루 평균 세션 횟수

실행 계획

- 대상 규모: Day 0 이탈 위험 세그먼트 중 5000명 (A/B 각 2500명)
- 기간: 2주 (유의미한 재방문 패턴 관찰을 위해)
- 분석 방법
 - 기간 종료 이후 두 군의 1일차 재방문율 차이를 검정 (z-test)
 - Secondary KPIs 차이에 대한 검정 (결제 전환에 대한 chi-square 검정, 세션 횟수에 대한 t-test)
- 실패 기준
 - Primary KPI p-value $\geq 0.05 \rightarrow$ 가설 기각,
 - Treat 그룹의 부작용(세션 감소, ARPPU 저하) 확인 시 재검토

분석 배경

- 방문 고객의 익일 재방문은 고객 리텐션 및 LTV 증대의 핵심 요소
- 사용자 로그 데이터를 통해 체험 후 행동 패턴을 정밀 분석하고, 모델을 개발함으로써 맞춤형 마케팅·운영 전략 수립을 통해 재방문율 향상 및 수익성 극대화를 도모

분석 목표

- 재방문 예측 모델을 통해 익일 방문 여부를 높은 정확도로 분류하고, 중요도가 높은 변수들을 통해 더 나은 성능의 모델 설계

사용 데이터

- 공유 오피스 무료체험 사용자의 출입 데이터 테이블
 - 6,000명의 공유 오피스 사용자의 출입 로그 및 체류 시간 데이터
 - 주요 테이블: 출입 기록 (trial_access_log), 무료 체험 신청 (trial_register), 무료 체험 신청자 결제 여부(trial_payment), 지점 정보(site_area) 등
 - 주요 컬럼: 사용자 ID (user_uuid), 체크인 - 체크아웃 여부 (checkin), 입퇴실 시각 (cdate) 등

분석 과정

데이터 전처리

- 입실 기록과 퇴실 기록이 매칭되는 경우를 확인하고, 그렇지 않은 로그는 제거
- 범주형 자료에 Label Encoding 적용 및 날씨 관련 파생변수 생성
- 원본 데이터에 반응 변수가 존재하지 않았기 때문에 ‘익일 방문 여부’라는 이진형 반응 변수를 생성
- 반응 변수에 데이터 불균형이 존재하여 SMOTE 기법을 적용

모델링

- 총 4개의 머신 러닝 모델 (Logistic Regression, Random Forest, LightGBM, Stacking) 에 대해 학습 데이터를 통한 모델 적합 수행
- TimeSeriesSplit을 활용해 시계열 교차검증을 적용하고, Optuna를 사용하여 모델 별 최적의 분류 성능을 확인
- 3개의 성능 평가 척도 (ROC-AUC, Precision, F1-Score)에 대해 최고의 성능을 보이는 머신 러닝 모델 확인


분석 결과

각 모델 별 분류 성능 비교 결과

Method	HPO	ROC-AUC	Class	Precision	Recall	F1-Score
LR	Default	0.7809	0	0.8932	0.6105	0.7253
			1	0.5575	0.8705	0.6797
	Optuna	0.7777	0	0.8725	0.6329	0.7336
			1	0.5621	0.8359	0.6722
RF	Default	0.8088	0	0.7640	0.7945	0.7790
			1	0.6078	0.5648	0.5855
	Optuna	0.8077	0	0.8786	0.6767	0.7646
			1	0.5926	0.8342	0.6930
LGBM	Default	0.8216	0	0.8049	0.7673	0.7856
			1	0.6188	0.6701	0.6434
	Optuna	0.8222	0	0.8819	0.6835	0.7702
			1	0.5988	0.8377	0.6983
Stacking	Default	0.7467	0	0.6436	0.9620	0.7713
			1	0.4507	0.0553	0.0985
	Optuna	0.8209	0	0.7878	0.7770	0.7824
			1	0.6138	0.6287	0.6212

- 최고 성능 모델은 Optuna 튜닝을 거친 LightGBM으로, 타 모델 대비 ROC-AUC가 우수하였다. 또한 모델이 각 Class의 Precision과 Recall도 타 모델 대비 준수하여 재방문자를 놓치지 않고 올바르게 찾아냈음을 확인할 수 있었다.

Feature Importance Plot



인사이트

- 두 변수 중요도 그래프 비교 결과, 공통적으로 체류시간이 중요하다고 판단되는 변수였으며, LGBM 모델에선 날씨 변수가 모델 성능에 큰 영향을 미쳤음
- 스태킹 모델은 LightGBM 모델 대비 성능 향상이 크지 않았기 때문에 관리 편의성을 고려해 LightGBM을 중심으로 한 예측 모델 운용 고려

추가 개선 방향

- 사용자 세그먼트 별 피드백 구축: 체험 이후 만족도 설문·NPS 점수 등을 모델에 피드백하여 예측 정확도 지속 개선
- 모델 운영 모니터링 & 재학습 주기 단축: 예측 성능이 떨어지는 기간(예: 계절별 변동) 식별 후 주기적 훈련 체계 구축