

프로젝트 개요

- 목표: 서비스 초기 사용자의 높은 이탈률 문제 해결. ‘Aha-Moment’ (최소 1회 수강) 경험 후 사용자의 행동 패턴을 분석하여, 재방문율을 높이고 유료 전환 가능성을 증대시키는 전략 수립
- 분석 방법: 사용자를 '0일차 이탈자'와 '1일차 재방문자'로 분류하고, 두 집단의 학습 패턴, 리텐션, KPI를 비교 분석. 분석 결과를 바탕으로 게이미피케이션 요소를 도입하는 A/B 테스트를 설계하여 재방문 유도 효과 검증.
- 데이터: 22년 1월 ~ 23년 12월까지의 온라인 교육 콘텐츠 구독 서비스의 사용자 행동 로그

실험 가설

“Aha-Moment를 겪은 다음 날(1일차), 서비스에 다시 방문한 사용자 집단은 이탈 집단 대비 **KPI 지표**가 유의미하게 높다”


분석 과정

- 데이터 전처리
  - 회원 가입을 한 사용자 ID를 추출하여 새로운 사용자 정보 테이블 생성
  - 사용자 행동 기반 분석을 이용한 사용자 세그먼트 라벨 생성

AARRR 프레임 워크 정의

| 단계          | 지표                | 설명                        |
|-------------|-------------------|---------------------------|
| Acquisition | 2022년 이후 가입 사용자 수 | 실험 대상 Pool 정의             |
| Activation  | 최소 1개의 강의 수강      | ‘Aha-Moment’ 를 느낀 시점      |
| Retention   | 다음 날 재방문율         | Activation 다음 날 접속 비율 (%) |
| Revenue     | 구독으로 이어진 사용자 수    | 결제 로그가 존재하는 사용자           |
| Referral    | -                 | 데이터 상 측정 불가               |



탐색적 자료 분석



- 22년 하반기 가입자 수는 완만히 감소하다가 23년 1월, 300% 가량 급증하였다.

| 주요 코호트의 롤링 리텐션 히트맵 |        |        |        |         |         |
|--------------------|--------|--------|--------|---------|---------|
| 코호트                | D0     | D1 생존율 | D7 생존율 | D14 생존율 | D28 생존율 |
| Jan-22             | 1.0000 | 0.3960 | 0.3570 | 0.3380  | 0.3120  |
| Nov-22             | 1.0000 | 0.4890 | 0.4460 | 0.4190  | 0.3530  |
| Feb-23             | 1.0000 | 0.3030 | 0.2370 | 0.2000  | 0.1680  |
| Aug-23             | 1.0000 | 0.2790 | 0.2040 | 0.1740  | 0.1380  |

- 0일차 → 1일차 평균 롤링 리텐션이 대부분 크게 감소하는 경향을 확인
- 즉, 1일차 재방문이 서비스의 리텐션 개선의 최우선 허들이라고 할 수 있음



- 0일차 이탈자
  - 중앙값 약 2회, IQR 약 1~4회 → 전체 수강 횟수가 낮아 학습 몰입도가 부족.
  - 짧은 학습 시간으로 서비스 체험이 제한적임.
- 1일차 재방문자
  - 중앙값 약 7회, 3사분위수 약 12회 → Day 0 이탈자(중앙값 약 2회)에 비해 훨씬 많은 레슨을 완료.
  - 평균 학습 시간이 비교적 길기 때문에 학습 몰입도가 이탈자보다 큼

## 분석 인사이트


| 구분       | 활동 일 수 (일) | 결제 전환률 (%) | 일 평균 세션 체류 (회) | ARPPU (원) |
|----------|------------|------------|----------------|-----------|
| 0일차 이탈자  | 1.55       | 8.02       | 0.1            | 76,469    |
| 1일차 재방문자 | 8.04       | 47.49      | 1.5            | 74,572    |

- 0일차 이탈자 : 평균 활동 일수 1.55일, 일 평균 세션 체류 0.1회 → 체험 단계에서 빠르게 이탈, 서비스 이해 부족. 결제 전환율 8.02%에 불과해, 단기 체험만으로는 유료 전환 동기 부여가 미흡
- 1일차 재방문자 : 평균 활동 일수 8.04일, 일 평균 세션 체류 1.5회 → 적극적 서비스 이용 및 학습 몰입도 높음. 결제 전환율 47.49%로 월등히 높아, 재방문 이후 ‘유료 전환’ 가능성이 크게 상승
- ARPPU(사용자당 평균 매출) 비교: 이탈자의 개별 지불액은 약간 높으나, 재방문자의 높은 전환율 덕분에 전체 매출 기여도는 재방문자 세그먼트가 더 큼


## 개선 사항 제안 및 기대 효과

| 전략                    | 설명                                        | 기대 효과 및 KPI                                                                                                          |
|-----------------------|-------------------------------------------|----------------------------------------------------------------------------------------------------------------------|
| 게이미피케이션               | 행동 지표를 기반으로 유저에게 시각적·심리적 보상을 제공하여 동기 강화   | <ul style="list-style-type: none"> <li>치장 아이템 획득율</li> <li>평균 세션 수 증가율</li> <li>결제 전환율 변화</li> </ul>                 |
| 분기·시즌 별 마케팅 및 프로모션 강화 | 시즌 수요를 활용해 단기 유입을 증대, 이후 연속 결제 및 리텐션 을 유도 | <ul style="list-style-type: none"> <li>프로모션 코드 사용률</li> <li>첫 결제 후 재구독 비율</li> <li>구독 지속 기간 및 LTV 비교</li> </ul>      |
| 장기 충성 사용자 대상 특별 혜택 강화 | 최상위 LTV 유저(파워 유저)를 식별해 이탈 방지 및 독점적 경험 제공  | <ul style="list-style-type: none"> <li>독점 콘텐츠 참여율</li> <li>파워 유저의 리퍼럴 수</li> <li>파워 유저가 유입 시킨 유저 의 LTV 비교</li> </ul> |

A/B 테스트 설계



Control 집단 대시보드



Treat 집단 대시보드

가설

- 문제 인식: 사용자들의 1일차 재방문율이 낮아 후속 전환의 기회가 상실됨.
- 가설: 메인 대시보드에 칭호와 학습 상황과 같은 게이미피케이션 요소를 삽입하면 1일차 재방문율과 결제 전환률이 상승할 것이다.

설계

| 구분             | Control          | Treat                |
|----------------|------------------|----------------------|
| 화면 구성          | 기본 수강 목록만 노출     | 챌린지 칭호 + 수강목록 노출     |
| Call To Action | “학습 이어가기” 버튼     | 챌린지 칭호 클릭 → 보상 안내 노출 |
| 타겟 사용자         | Day 0 이탈 위험 세그먼트 | 동일 세그먼트              |

지표

- Primary KPI: 1일차 재방문율
- Secondary KPIs: 결제 전환률, ARPPU, 하루 평균 세션 횟수

실행 계획

- 대상 규모: Day 0 이탈 위험 세그먼트 중 5000명 (A/B 각 2500명)
- 기간: 2주 (유의미한 재방문 패턴 관찰을 위해)
- 분석 방법
  1. 기간 종료 이후 두 군의 1일차 재방문율 차이를 검정 (z-test)
  2. Secondary KPIs 차이에 대한 검정 (결제 전환에 대한 chi-square 검정, 세션 횟수에 대한 t-test)
- 실험 실패 기준
  1. Primary KPI p-value  $\geq 0.05 \rightarrow$  가설 기각,
  2. Treat 그룹의 부작용(세션 감소, ARPPU 저하) 확인 시 재검토

# PROJECT 2

## 일일 전기 사용량 데이터를 이용한 전력 수요 예측 모델링

프로젝트 기간: 2024. 12. 05 ~ 2024. 12. 19


이름: 유윤종  
yooyoon97@gmail.com

### 프로젝트 개요


- 목표: 과거 한국의 전력 수요 및 관련 변수를 분석하여 미래 수요 예측 모델 개발
- 분석 방법: 알고리즘 성능을 비교하기 위하여 통계 및 머신러닝 알고리즘을 사용. R-squared, MAPE로 성능 평가. (SARIMA, XGBoost)
- 데이터: 일별 전력 수요, 기온, 공휴일 정보 (2010 ~ 2024)
- 주요 기술: pandas, numpy, scikit-learn, **SARIMA**, Statsmodels, XGBoost,

### 분석 과정


#### 탐색적 자료 분석



- 전력 수요는 시간에 지남에 따라 장기적으로 우상향하는 추세를 보였다.



- 산점도 분석 결과 기온이 낮을 때는 난방, 높을 때는 냉방으로 인해 전력 수요가 증가하는 명확한 U자 형태의 패턴을 발견하였다.



- 시계열을 분해 한 뒤 연간 평균 계절성을 통해 여름과 겨울에 수요가 급증하는 패턴을 발견하였다. 즉, 전력 수요량에 강한 계절성이 존재함을 입증하였다.



모델링 프로세스

1. SARIMA (계절성 ARIMA) 모형

- 정상성 검정: ADF 검정을 통해 시계열의 정상성을 확인하고, 차분을 통해 시계열 모형의 기본 가정을 만족
- 차수 결정: ACF/PACF 플롯을 분석하여 SARIMA 모형의 최적 차수 결정

2. 머신러닝 기반 예측 모델




- 피처 엔지니어링: 시계열 데이터를 모델이 학습할 수 있게 시간기반 특성을 생성
- 모델 훈련 및 성능 비교: 훈련 뒤 가장 높은 성능의 모델을 최종으로 선택

모델 성능 비교 및 평가

| Model   | Method      | MAPE   | R <sup>2</sup> |
|---------|-------------|--------|----------------|
| SARIMAX | Baseline    | 0.0263 | 0.9113         |
|         | Log(watt)   | 0.0246 | 0.9201         |
| XGBoost | Baseline    | 0.0102 | 0.9663         |
|         | Grid Search | 0.0146 | 0.9281         |

- XGBoost 모델은 복잡하고 비선형적인 패턴까지 훨씬 정밀하게 예측했기 때문에 시계열 회귀 모형 대비 우수한 성능을 기록

각 모델의 예측 결과



- 실제값과 예측값 비교 결과, XGBoost 모델이 실제 값의 변동성을 가장 유사하게 예측하였다.

# PROJECT 3


## Airflow 기반 결제 예측 및 자동화 파이프라인 구축

프로젝트 기간: 2025. 07. 10 ~ 2025. 08. 13  
이름: 유윤중  
yooyoon97@gmail.com

### 프로젝트 개요


- 목표: 사용자 행동 로그 데이터를 기반으로 결제 여부를 예측하는 머신러닝 모델 개발. 예측 결과를 슬랙으로 자동 전송하는 데이터 파이프라인 구축
- 분석 방법: Airflow DAG를 직접 설계하여 데이터 처리 및 모델 예측 과정을 자동화했으며, Docker를 이용해 개발 환경을 구축하여 배포 안정성을 확보.
- 데이터: 23년 7월 ~ 23년 8월까지의 익명 SNS 서비스의 사용자 행동 로그 데이터
- 주요 기술: **Airflow**, **Docker**, **LightGBM**, **scikit-learn**, **Optuna**

### 도커 환경 구축



- Docker Compose를 사용해 Airflow Webserver와 Scheduler 환경을 컨테이너로 구성
- 로컬 환경에서도 손쉽게 파이프라인 테스트 가능

### 데이터 파이프라인 아키텍처



1. CSV Data
  - 사용자 행동 로그 데이터가 CSV 파일 형태로 저장
  - 모델 학습과 예측의 입력 데이터 원본
2. EDA 및 전처리
  - 결측치 처리, 이상치 제거, 피처 엔지니어링 수행
  - 데이터 분포와 특성을 분석해 모델링 방향 결정
3. 머신러닝 모델 적합 및 최적 모델 배포
  - LightGBM, XGBoost, CatBoost 모델 사용
  - Optuna를 통해 하이퍼파라미터 최적화
  - 최적 모델을 Pickle 형태로 저장
4. 도커 환경 구축
  - 모델 예측 코드를 Docker 이미지로 빌드
5. 에어플로우 자동화
  - DAG(Directed Acyclic Graph)를 통해 전체 파이프라인 실행 순서 정의
6. 슬랙 알림 전송
  - 파이프라인 실행 완료 후 Slack API로 성능 지표 전송

## Airflow 자동화

### DAGs

All6

Active1


Paused5

Running1

Failed0

Filter DAG

| <div><div>i</div></div> DAG                                                                                                                 | Owner   | Runs                                                       | Schedule |
|---------------------------------------------------------------------------------------------------------------------------------------------|---------|------------------------------------------------------------|----------|
| <div><div><div></div></div><div>e2e_modeling_pipeline_final</div><div><div>e2e</div><div>ml</div><div>pipeline</div></div></div>            | airflow | <div><div></div><div>3</div><div>1</div><div>7</div></div> | None     |
| <div><div><div></div></div><div>e2e_modeling_pipeline_with_full_report</div><div><div>e2e</div><div>ml</div><div>pipeline</div></div></div> | airflow | <div><div></div><div>1</div><div></div><div>2</div></div>  | None     |
| <div><div><div></div></div><div>full_modeling_pipeline_v1</div><div><div>e2e</div><div>ml</div><div>pipeline</div></div></div>              | airflow | <div><div></div><div></div><div></div><div></div></div>    | None     |
| <div><div><div></div></div><div>hello_airflow</div></div>                                                                                   | airflow | <div><div></div><div></div><div></div><div></div></div>    | @daily   |
| <div><div><div></div></div><div>modeling_pipeline_with_slack_v3</div><div><div>ml</div><div>pipeline</div><div>refactored</div></div></div> | airflow | <div><div></div><div>2</div><div></div><div>8</div></div>  | None     |
| <div><div><div></div></div><div>read_user_data</div></div>                                                                                  | airflow | <div><div></div><div></div><div></div><div></div></div>    | None     |



- Airflow DAG를 작성해 전처리 → 모델 학습/평가 → Slack 알림 발송 순으로 자동화
- 각 단계는 PythonOperator로 구현되어 모듈화 및 재사용 가능
- DAG 실행 상태와 결과를 Web UI를 통해 실시간 모니터링 가능
- 스케줄 설정으로 주기적인 모델 재학습 및 예측 수행

## Slack 알림 발송

**Demo App** 오후 7:31  
🎉 모델링 파이프라인 완료!  
🚀 모델링 파이프라인 주요 결과 🚀

- Best Threshold: 0.2462
- Test ROC AUC: 0.9043
- Test PR AUC: 0.0978

### Classification Report:

|              | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| Non-Payer    | 0.99      | 0.99   | 0.99     | 32943   |
| Payer        | 0.16      | 0.26   | 0.20     | 243     |
| accuracy     |           |        | 0.99     | 33186   |
| macro avg    | 0.58      | 0.62   | 0.60     | 33186   |
| weighted avg | 0.99      | 0.99   | 0.99     | 33186   |

- Airflow 실행 완료 시 Slack API를 통해 주요 성능 지표 전송
- Precision, Recall, F1-score 등 Classification Report 첨부로 모델 상태 파악 용이

## 파이프라인 개선 방안

- 모델/데이터 드리프트 감지 알고리즘 적용
  - 예측 성능 저하를 방지하기 위해 모델 드리프트와 데이터 분포 변화를 실시간으로 감지
- GCP 환경에 적용 가능하도록 확장
  - 데이터 저장: BigQuery, Cloud Storage
  - 워크플로우 오케스트레이션: Cloud Composer (Airflow)
  - 모델 배포: Vertex AI