

- 핵심 성과
- 사용자 행동 로그 분석을 통해 '첫날 재방문 ' 이 결제 전환율을 약 5.9배 높이는 핵심 지표임을 규명. 게이미피케이션 기반의 A/B 테스트를 설계하여 데이터 기반의 서비스 개선 전략을 제시
- 프로젝트 개요
- 목표: 서비스 초기 사용자의 높은 이탈률 문제 해결. 'Aha-Moment' (최소 1회 수강) 경험 후 사용자의 행동 패턴을 분석하여, 재방문율을 높이고 유료 전환 가능성을 증대 시키는 전략 수립
 - 분석 방법: 사용자를 '0일차 이탈자'와 '1일차 재방문자'로 분류하고, 두 집단의 학습 패턴, 리텐션, KPI를 비교 분석. 분석 결과를 바탕으로 게이미피케이션 요소를 도입하는 A/B 테스트를 설계하여 재방문 유도 효과 검증.
 - 데이터: 22년 1월 ~ 23년 12월까지의 온라인 교육 콘텐츠 구독 서비스의 사용자 행동 로그


실험 가설

“Aha-Moment를 겪은 다음 날(1일차), 서비스에 다시 방문한 사용자 집단은 이탈 집단 대비 KPI 지표가 유의미하게 높다”

- 분석 과정
- 데이터 전처리
 - 회원 가입을 한 사용자 ID를 추출하여 새로운 사용자 정보 테이블 생성
 - 사용자 행동 기반 분석을 이용한 사용자 재방문 여부 세그먼트 라벨 생성



■ AARRR 프레임 워크 정의

단계	지표	설명
Acquisition	2022년 이후 가입 사용자 수	실험 대상 Pool 정의
Activation	최소 1개의 강의 수강	'Aha-Moment' 를 느낀 시점
Retention	다음 날 재방문율	Activation 다음 날 접속 비율 (%)
Revenue	구독으로 이어진 사용자 수	결제 로그가 존재하는 사용자
Referral	-	데이터 상 측정 불가



주요 코호트의 롤링 리텐션 히트맵					
코호트	D0	D1 생존율	D7 생존율	D14 생존율	D28 생존율
Jan-22	1.0000	0.3960	0.3570	0.3380	0.3120
Nov-22	1.0000	0.4890	0.4460	0.4190	0.3530
Feb-23	1.0000	0.3030	0.2370	0.2000	0.1680
Aug-23	1.0000	0.2790	0.2040	0.1740	0.1380

- 0일차 → 1일차 평균 롤링 리텐션이 대부분 크게 감소하는 경향을 확인
- 즉, 1일차 재방문이 서비스의 리텐션 개선의 최우선 허들이라고 할 수 있음



- 0일차 이탈자
 - 중앙값 약 2회, IQR 약 1~4회 → 전체 수강 횟수가 낮아 학습 몰입도가 부족.
 - 짧은 학습 시간으로 서비스 체험이 제한적임.
- 1일차 재방문자
 - 중앙값 약 7회, 3사분위수 약 12회 → Day 0 이탈자(중앙값 약 2회)에 비해 훨씬 많은 레슨을 완료.
 - 평균 학습 시간이 비교적 길기 때문에 학습 몰입도가 이탈자보다 큼

분석 인사이트


구분	활동 일 수 (일)	결제 전환률 (%)	일 평균 세션 체류 (회)	ARPPU (원)
0일차 이탈자	1.55	8.02	0.1	76,469
1일차 재방문자	8.04	47.49	1.5	74,572

- 0일차 이탈자 : 평균 활동 일수 1.55일, 일 평균 세션 체류 0.1회 → 체험 단계에서 빠르게 이탈, 서비스 이해 부족. 결제 전환율 8.02%에 불과해, 단기 체험만으로는 유료 전환 동기 부여가 미흡
- 1일차 재방문자 : 평균 활동 일수 8.04일, 일 평균 세션 체류 1.5회 → 적극적 서비스 이용 및 학습 몰입도 높음. 결제 전환율 47.49%로 월등히 높아, 재방문 이후 '유료 전환' 가능성이 크게 상승
- ARPPU(사용자당 평균 매출) 비교: 이탈자의 개별 지불액은 높으나, 전체 사용자의 13%에 불과한 1일차 재방문자 그룹이 이탈 그룹에 비해 매출을 창출하는 비율이 높음을 규명


개선 사항 및 기대 효과

전략	설명	기대 효과 및 KPI
게이미피케이션	행동 지표를 기반으로 유저에게 시각적·심리적 보상을 제공하여 동기 강화	- 치장 아이템 획득율 - 평균 세션 수 증가율 - 결제 전환율 변화
분기·시즌 별 마케팅 및 프로모션 강화	시즌 수요를 활용해 단기 유입을 증대, 이후 연속 결제 및 리텐션을 유도	- 프로모션 코드 사용률 - 첫 결제 후 재구독 비율 - 구독 지속 기간 및 LTV 비교
장기 충성 사용자 대상 특별 혜택 강화 (RFM 분석)	최상위 LTV 유저(파워 유저)를 식별해 이탈 방지 및 독점적 경험 제공	- 독점 콘텐츠 참여율 - 파워 유저의 리퍼럴 수 - 파워 유저가 유입 시킨 유저의 LTV 비교

A/B 테스트 설계



Control 집단 대시보드



Treat 집단 대시보드

가설

- 문제 인식: 사용자들의 1일차 재방문율이 낮아 후속 전환의 기회가 상실됨.
- 가설: 메인 대시보드에 칭호와 학습 상황과 같은 게이미피케이션 요소를 삽입하면 1일차 재방문율과 결제 전환률이 상승할 것이다.

설계

구분	Control	Treat
화면 구성	기본 수강 목록만 노출	챌린지 칭호 + 수강목록 노출
Call To Action	“학습 이어가기” 버튼	챌린지 칭호 클릭 → 보상 안내 노출
타겟 사용자	Day 0 이탈 위험 세그먼트	동일 세그먼트

지표

- Primary KPI: 1일차 재방문율
- Secondary KPIs: 결제 전환률, ARPPU, 하루 평균 세션 횟수

실행 계획

- 대상 규모: Day 0 이탈 위험 세그먼트 중 5000명 (A/B 각 2500명)
- 기간: 2주 (유의미한 재방문 패턴 관찰을 위해)
- 분석 방법
 1. 기간 종료 이후 두 군의 1일차 재방문율 차이를 검정 (z-test)
 2. Secondary KPIs 차이에 대한 검정 (결제 전환에 대한 chi-square 검정, 세션 횟수에 대한 t-test)
- 실험 실패 기준
 1. Primary KPI p-value ≥ 0.05 → 가설 기각,
 2. Treat 그룹의 부작용(세션 감소, ARPPU 저하) 확인 시 재검토

핵심 성과

- Docker와 Airflow를 기반으로 데이터 전처리, 모델 학습, 예측, Slack 결과 리포팅까지 이어지는 MLOps 파이프라인을 구축하여 운영 및 배포 자동화 시뮬레이션을 운영하고, 월 별 단위 로그를 분석


프로젝트 개요

- 목표: 사용자 행동 로그 데이터를 기반으로 결제 여부를 예측하는 머신러닝 모델 개발. 예측 결과를 Slack으로 자동 전송하는 데이터 파이프라인 구축
- 분석 방법: Airflow DAG를 직접 설계하여 데이터 처리 및 모델 예측 과정을 자동화했으며, Docker를 이용해 개발 환경을 구축하여 배포 안정성을 확보.
- 데이터: 23년 7월 ~ 23년 8월까지의 익명 SNS 서비스의 사용자 행동 로그 데이터
- 주요 기술: Airflow, Docker, LightGBM

도커 환경 구축

- Docker Compose를 사용해 Airflow Webserver와 Scheduler 환경을 컨테이너로 구성
- 테스트를 위한 로컬 환경에서의 파이프라인 구축 의도

데이터 파이프라인 아키텍처



1. CSV Data
 - 사용자 행동 로그 데이터를 CSV 파일 형태로 수집
 - 모델 학습용 데이터와 사용자 행동 정보가 담긴 데이터
2. EDA 및 전처리
 - 결측치 처리, 이상치 제거, 피처 엔지니어링 수행
 - 데이터 분포와 특성을 분석해 모델링 방향 결정
3. 머신러닝 모델 적합 및 최적 모델 배포
 - LightGBM, XGBoost, CatBoost 모델 사용
 - Optuna를 통해 하이퍼파라미터 최적화
 - 최적 모델을 Pickle 형태로 저장
4. 도커 환경 구축
 - 모델 예측 코드를 Docker 이미지로 빌드
5. 에어플로우 자동화
 - DAG(Directed Acyclic Graph)를 통해 전체 파이프라인 실행 순서 정의
6. 슬랙 알림 전송
 - 파이프라인 실행 완료 후 Slack API로 성능 지표 채팅 전송

Airflow 자동화

DAGs

All6

Active1


Paused5

Running1

Failed0

Filter DAG

i DAG	Owner	Runs	Schedule
e2e_modeling_pipeline_final e2e ml pipeline	airflow	3 1 7	None
e2e_modeling_pipeline_with_full_report e2e ml pipeline	airflow	1 2	None
full_modeling_pipeline_v1 e2e ml pipeline	airflow		None
hello_airflow	airflow		@daily
modeling_pipeline_with_slack_v3 ml pipeline refactored	airflow	2 8	None
read_user_data	airflow		None



- Airflow DAG를 작성해 수집, 전처리 → 모델 학습/평가 → Slack 알림 발송 순으로 자동화
- 각 단계는 PythonOperator로 구현되어 모듈화 및 재사용 가능
- DAG 실행 상태와 결과를 Web UI를 통해 실시간 모니터링 가능
- 스케줄 설정으로 주기적인 모델 재학습 및 예측 수행

Slack 알림 발송

Demo App 앱 오후 7:31
🎉 모델링 파이프라인 완료!

🚀 모델링 파이프라인 주요 결과 🚀

- Best Threshold: 0.2462
- Test ROC AUC: 0.9043
- Test PR AUC: 0.0978

Classification Report:

	precision	recall	f1-score	support
Non-Payer	0.99	0.99	0.99	32943
Payer	0.16	0.26	0.20	243
accuracy			0.99	33186
macro avg	0.58	0.62	0.60	33186
weighted avg	0.99	0.99	0.99	33186

- Airflow 실행 완료 시 Slack API를 통해 주요 성능 지표 전송
- Precision, Recall, F1-score 등 Classification Report 첨부로 모델 상태 파악을 용이하게 함

파이프라인 개선 방안

- 모델/데이터 드리프트 감지 알고리즘 적용
 - 예측 성능 저하를 방지하기 위해 모델 드리프트와 데이터 분포 변화를 실시간으로 감지 (K-S 검정 등)
- GCP 환경에 적용 가능하도록 확장
 - 데이터 저장: BigQuery, Cloud Storage
 - 워크플로우 오케스트레이션: Cloud Composer (Airflow)
 - 모델 배포: Vertex AI

시계열 분석 및 머신러닝을 활용한 일별 최대 전력 수요 예측 모델 개발

핵심 성과


- 계절성 회귀 모형 및 머신러닝 모델 비교를 통해 XGBoost가 전력 수요 예측에서 가장 우수한 성능(MAPE: 0.0102, $\mathcal{R}^2$: 0.9663) 을 기록함을 입증.

프로젝트 개요


- 목표: 과거 한국의 전력 수요 및 관련 변수를 분석하여 미래 수요 예측 모델 개발
- 분석 방법: 알고리즘 성능을 비교하기 위하여 통계 및 머신러닝 알고리즘을 사용.
R-squared, MAPE로 성능 평가. (SARIMA, XGBoost)
- 데이터: 일별 전력 수요, 기온, 공휴일 정보 (2010 ~ 2024)
- 주요 기술: pandas, numpy, scikit-learn, SARIMA, Statsmodels, XGBoost

분석 과정

- ## ■ 탐색적 자료 분석



- 전력 수요는 시간에 지남에 따라 장기적으로 우상향하는 추세를 보였다.



- 산점도 분석 결과 기온이 낮을 때는 난방, 높을 때는 냉방으로 인해 전력 수요가 증가하는 명확한 U자 형태의 패턴을 발견하였다.



- 시계열을 분해 한 뒤 연간 평균 계절성을 통해 여름과 겨울에 수요가 급증하는 패턴을 발견하였다. 즉, 전력 수요량에 강한 계절성이 존재함을 입증하였다.

■ 모델링 프로세스

1. SARIMA (계절성 ARIMA) 모형

- 정상성 검정: ADF 검정을 통해 시계열의 정상성을 확인하고, 차분을 통해 시계열 모형의 기본 가정을 만족
- 차수 결정: ACF/PACF 플롯을 분석하여 SARIMA 모형의 최적 차수 결정

2. 머신러닝 기반 예측 모델




- 피처 엔지니어링: 시계열 데이터를 모델이 학습할 수 있게 시간기반 특성을 생성
- 모델 훈련 및 성능 비교: 훈련 뒤 가장 높은 성능의 모델을 최종으로 선택

■ 모델 성능 비교 및 평가

Model	Method	MAPE	R ²
SARIMAX	Baseline	0.0263	0.9113
	Log(watt)	0.0246	0.9201
XGBoost	Baseline	0.0102	0.9663
	Grid Search	0.0146	0.9281

- XGBoost 모델은 복잡하고 비선형적인 패턴까지 훨씬 정밀하게 예측했기 때문에 시계열 회귀 모형 대비 우수한 성능을 기록

■ 각 모델의 예측 결과



- 실제값과 예측값 비교 결과, XGBoost 모델이 실제 값의 변동성을 가장 유사하게 예측하였다.